

## **מבוא**

נושא הזוכה לעניין מחקרי רב בתחום ממשקי מוח-מחשב הוא הדמיון המוטורי (Venkatachalam, k., et al, 2020), מונח המתאר מצב בו אדם מדמיון תנועה מוטורית שהוא עצמו מבצע. ניתן לומר שהדמיון המוטורי פותח צוהר לתהליכים מוטוריים קוגניטיביים ובפרט לשליטה המוטורית, (Jörn Munzert, Britta Lorey, Karen Zentgraf, 2009), ויישומים אפשריים שלו מהווים פוטנציאל גדול בתחומי הבינה המלאכותית, שיקום עצבי, פרוטזה עצבית, וגיימינג.

מערכות EEG הן אחת מהשיטות הנפוצות לתיעוד הפעילות העצבית במוח ולחקירת הדמיון המוטורי, כאשר אלקטרודות C3 ו-C4 מתעדות פעילות המקושרת לתנועה מוטורית ולדמיון שלתנועה כזו. כאשר מיקום האלקטרודה הוא "קונטרה לטרלי" למיקום הגפה המופעלת. ניתן לתאר את הפעילות החשמלית הנקלטת באלקטרודות אלו כגלי מוח, ולחלק אותם לסוגים של תדרים. גלי האלפא (8-13 Hz) והבטא הנמוכים (13-20 Hz) מקושרים לשליטה מוטורית ובפרט לדמיון מוטורי, ולכן ציפנו לראות מדדים גבוהים יותר בטווח תדרים זה.

בניסוי שלנו, התקבל מידע שתועד באלקטרודות אלו עבור נבדק שביצע דמיון מוטורי, ולכל חזרה בה דמיון תנועה, התקבל דיווח של הנבדק האם דמיון תנועה ביד ימין או ביד שמאל. מטרת הניסוי הייתה לבנות מסווג שיבחין על פי אותות EEG, האם התרחש דמיון מוטורי ביד ימין או ביד שמאל. הצגנו את המידע במספר דרכים כדי לנסות למצוא מאפיינים שיעזרו לבצע הבחנה כזו.

דרך אחת הייתה להסתכל על 20 חזרות אקראיות מכל תנאי, ולנסות להתבונן בנתונים שנקלטו עבור חזרה מסוימת באופן נקי (ראה גרף 1), ולנסות לזהות הבדלים בין החזרות או מאפיינים כלליים. דרך נוספת הייתה לחשב power spectrum בעזרת פונקציית pwelch (גרף 3), כדי להבדיל בין התדרים בעוצמות שהתקבלו עבורם. בהמשך הצגנו ספקטוגרמות בהן ניתן יהיה לזהות הבדלים משמעותיים במרחב התדר כתלות במרחב הזמן, ולחלץ מאפיינים נוספים שיסייעו להבחנה. במרחב הזמן ציפנו להבדלים משמעותיים ב-3 השניות האחרונות (מתוך 6 שניות לכל חזרה), טווח הזמן בו התרחש הדמיון של התנועה. בנוסף ניסינו למצוא מאפיינים נוספים, כמו סטיית תקן, Power Spectra, Spectral Entropy, ועוד, על פני כלל המידע ובפרט ברצועות התדרים בהן ציפנו ומצאנו הבדלים.

את ההבדלים הללו תירגמנו למאפיינים - פונקציות אשר בהנתן כל חזרה כקלט, יוצאו פלט (ראה היסטוגרמות המתארות את התפלגויות המאפיינים) שיסייעו למסווג לקבל החלטה מדויקת עבור כל חזרה. פונקציה אשר ערכי הפלט שלה מייצרים שתי התפלגויות שונות יחסית, בהצגת היסטוגרמה של חזרות יד שמאל וחזרות יד ימין, היא פונקציה שמבחינה טוב יחסית בין הרמות ותסייע להחלטת המסווג. נעזרנו גם בפונקציה Principal component analysis (PCA) כדי לבצע רדוקציה למימדי המאפיינים שמצאנו כדי להציג אותם ולדרג את היעילות שלהם (ראה גרפים 7-9 לדירוג המאפיינים, גרפים 10-11 – הצגת Scatter).

לטובת משימת הסיווג השתמשנו בפונקציית classify, המתבססת על המודל הלינארי Linear Discriminant Analysis, כדי לבדוק את יעילות הפיצ'רים ובכך לדייק את הסיווג. "אימנו" את המסווג ע"י הוצאת פיצ'רים ובחינתם בשיטת K-fold cross validation, בה מחלקים את החזרות בניסוי ל-K קבוצות רנדומליות, ובכל פעם לוקחים קבוצה אחרת שתהיה קבוצת מבחן, ושאר הקבוצות משמאות לאימות ההבחנות של המסווג. עבור כל "אימון" כזה נוכל לבדוק את רמת הדיוק, לחשב את ממוצע וסטיית תקן הדיוקים על פני האימונים, ולהסיק איזה מאפיינים אכן עוזרים לסווג בדיוק גבוה יותר. לבסוף, אחרי ששיפרנו את דיוק המאפיינים ובכך את דיוק המסווג, בחנו אותו על מידע מאותות EEG שלא נחשף קודם לכן.

## שיטות

בניסוי שלנו, התקבל מידע ממערכת EEG עבור 128 חזרות, ולכל חזרה משתנה בלתי תלוי - היד עברה דיווח הנבדק שהתרחש דמיון מוטורי, ב-2 רמות: יד ימין או יד שמאל. כל חזרה נמשכה 6 שניות, בתדירות דגימה של 128 דגימות לשניה, סה"כ 768 דגימות לכל חזרה. לכל דגימה נמדדו 2 ערכים (מלבד הרמה - לאיזה יד שייכת) ערך באלקטרודה C3 ונמדד ערך באלקטרודה C4.

מצורף קטע הקוד לאיתחול הפרמטרים לקליטה ועיבוד ראשון של המידע:

```

% Data related
C3 = 1;
C4 = 2;
typeHandLabeled = 3;
samplingRate = DataBase.samplingfrequency; % sampling rate of data
totalTrialTime = size(dataBase.data,2); % total time of each trial
startTimeImagination = 384; % the time that the subject starts motor imagination
numberOfTrials = size(dataBase.data,1);
numberOfFreq = 129;
SecondDuration = 128;
% Extracting ideces of activity in each class
rightHandLabeled = find(dataBase.attribute(4,:) > 0); % given indeces labed as right
leftHandLabeled = find(dataBase.attribute(3,:) > 0); % given indeces labed as left
nTrialsRight = size(rightHandLabeled,2); % In our experement 64
nTrialsLeft = size(leftHandLabeled,2); % In our experement 64

```

שנית, כדי למצוא מאפיינים נוספים במרחב התדר, נחשב לכל רמה בכל אחת מהאלקטרודות צפיפות של ה- (PSD) power spectral בעזרת הפונקציה pwelch. בפונקציית pwelch מגולם עיבוד המידע לרכיבים – "חלונות", עם חפיפה ביניהם, כדי לייצר רצף ברור יותר של הערכים ולזהות מאפיינים. בהשוואת גרפי הפלט, ננסה למצוא הבדלים בין הרמות. הפרמטרים לחישוב:

```

% Pwelch parameters
nWindows = 12;
sizeOfWindowPwelch = 150;
sizeOfPwelchVec = 391;
nOverlapPwelch = 70;

```

בקטע הקוד המצורף ניתן לראות את הפרמטרים המייצגים את מספר החלונות (12), גודל החלון שנבחר (150), כמות הרכיבים שהתקבלו (391, בגלל החפיפה הגדולה) ואת אחוז החפיפה (70). נתונים אלה נתנו תמונה בהירה להצגת המידע וזיהוי הבדלים.

## מצורפת שליחת הפונקציה לחישוב Pwelch:

### Generate power spectra for each trail separately

```
[PSRC3,PSRC4,PSLC3,PSLC4] = generatePwelch(rightHandLabeled,leftHandLabeled, ...
    startTimeImagination,totalTrialTime,C3,C4,samplingRate, ...
    sizeOfWindowPwelch,nOverLapPwelch,nTrialsRight,nTrialsLeft,sizeOfPwelchVec,f,fontSize,titleFontSize,dataBase);
```

כדי לזהות מאפיינים במרחב התדר כתלות בזמן (informative frequency bands) נעזרנו גם בספקטוגרמה, שתחושב בעזרת short-time fourier transform. השווינו בין הרמות עבור המידע שהתקבל בכל אחת מהאלקטרודות. בעזרת הפונקציה bandpower חישבנו מאפיינים מסויימים עבור כל אחת מהבדיקות, באופן המאפשר הבחנה בטווחי זמן ובטווחי תדרים מסויימים. מחקרים הראו שקיים קשר בין תנועת יד בבדיקה או אף דמיון של תנועה מוגבלת, לבין הגברת גלי ה-  $\mu$  (8-13 Hz) וגלי הבטא (13-30), (Athena Akrami et al, 2005), באופן שדמיון כזה יוכל לשמש כשליטה באותות כאלו לטובת בקרת ממשקי מחשב-מוח (Devi, S. S & ,Sivakami, A, 2015).

```
% Spectrogram parameters
sizeOfWindowSPEC = 128;
nOverLapSPEC = 110;
```

הפרמטרים לחישוב הספקטוגרמה:

### Calculating the spectrograms for all trials

```
[StotalR3 ,StotalR4 ,StotalL3 ,StotalL4] = generateSPEC(rightHandLabeled, ...
    leftHandLabeled,C4,C3,nTrialsRight,nTrialsLeft,sizeOfWindowSPEC,nOverLapSPEC,samplingRate,f,dataBase);

% Spectrogram visualization
SpectrogramVisualization(StotalR3,StotalL3,StotalR4,StotalL4,nTrialsRight,nTrialsLeft,fontSize,titleFontSize);
```

קוד הפונקציה המחזירה את חישוב והצגת הספקטוגרמות לכל אחד מהתנאים, בהחזרת הערכים Stotal, כאשר כל אחד מהם מתאים לתנאי שונה, לדוגמה StotalR3 מקבל את החישובים שהתקבלו עבור יד ימין באלקטרודה C3.

חילוץ המאפיינים - הפונקציה featureExtractor: מצורף קטע הקוד המקבל את הפרמטרים המתאימים לחישוב כלל המאפיינים אותם ניסינו לחלץ מהמידע שהתקבל כדי להבחין בין החזרות.

## feature extraction - COMPACT VERSION

```
% extended featuresMatrix - 16 predictors
% compact featuresMatrix - 3 predictors
featuresMatrix = featureExtractor(typeOfClassifier,numberOfTrials, ...
    numOffeatures,starTimeVARC3,starTimeVARC4,starTimeFreq18,samplingRate, ...
    totalTrialTime,starTimeFreq10,endTimefreq10C4, ...
    starTimeHighCloud,endTimeHighCloud, ...
    starTimeSpectralEntropy, ...
    starTimeApproxEntropyC3,starTimeApproxEntropyC4, ...
    endTimeApproxEntropyC3,endTimeApproxEntropyC4, ...
    starTimeImagination,starTimePSfeature, ...
    nOverLapPwelch,sizeOfPwelchVec,...
    sizeOfWindowPwelch,C3,C4,dataBase);

% Normalazing score
featuresMatrixNormalized = zscore(featuresMatrix);

if(strcmp(typeOfClassifier,"extended"))
    featureTable = array2table(featuresMatrixNormalized,'VariableNames',{'VARC3','VARC4','freq18C3','freq18C4','highCloudC3'});
else
    featureTable = array2table(featuresMatrixNormalized,'VariableNames',{'freq18C4','VARC3','VARC4'});
end

% indicationVec: labeled, trial(i) left labeled --> value(i) = 1
indicationVec = indicationvecINIT(numberOfTrials,typeHandLabeled, dataBase);
```

את פלט הפונקציה שמרנו במטריצת המאפיינים featuresMatrix, בה כל חזרה מיוצגת על ידי שורה, וכל עמודה מייצגת מאפיין. כל לכל חזרה ישנה שורה מתאימה במטריצה המייצגת את הערכים שהתקבלו עבורה מכל אחד מהמאפיינים. נירמול עבור מטריצה זו מספק אפשרות להשוות ביניהם ולעבד את הנתונים שהתקבלו בפונצקיות בהמשך, תוך שימשו במבנה נתונים נוסף שיאכלס את המידע.

בנוסף מצורף בניית וקטור האימות – indicationVec, שיסייע לבדיקת המסווגים שנאמן.

איתחול הפרמטרים עבור המאפיינים:

```
% Times for features
startTimeVARC3 = 512;
startTimeVARC4 = 555;
startTimeFreq18 = 660;
startTimeFreq10 = 652;
startTimeHighCloud = 630;
startTimePSfeature = 590;
startTimeSpectralEntropy = 256;
startTimeApproxEntropyC3 = 500;
startTimeApproxEntropyC4 = 400;
endTimeApproxEntropyC3 = 700;
endTimeApproxEntropyC4 = 750;
endTimeFreq10C4 = 740;
endTimeHighCloud = 730;
```

הפונקציה freq18 - חילוץ מאפיין ב frequency band, בתדרים 16-17 בזמנים המתאימים (פרמטרים מצורפים מטה) בעזרת הפונקציה bandpower:

```
function [freq18C3,freq18C4] = freq18(C3 ,C4 ,startTimeFreq18 ,totalTrialTime,samplingRate ,dataBase)

if(size(dataBase,2) ~= 1)
    % for extracting data from the test
    ResultC4 = bandpower(dataBase(:,startTimeFreq18:totalTrialTime,C4)',samplingRate,[16 17]);
    ResultC3 = bandpower(dataBase(:,startTimeFreq18:totalTrialTime,C3)',samplingRate,[16 17]);
else
    ResultC4 = bandpower(dataBase.data(:,startTimeFreq18:totalTrialTime,C4)',samplingRate,[16 17]);
    ResultC3 = bandpower(dataBase.data(:,startTimeFreq18:totalTrialTime,C3)',samplingRate,[16 17]);
end

freq18C3 = 10*log10(ResultC3);
freq18C4 = 10*log10(ResultC4);
```

עבור התוצאות נבצע נרמול בעזרת פונקציה לוגריתמית, מה שיסייע להשוות בין הנתונים. למעשה פונקציה זו ממשת את הוצאת המאפיינים לכל חזרה וחזרה עבור אחד הממצאים הבולטים שנציג בפרק התוצאות, בגרפים 4 ו-5, שם ימצא הסבר נוסף.

## הפונקציה VarianceFeature - חילוץ מאפיינים 2 ו-3 - השונות באלקטרודות:

```
function [VARC3,VARC4] = VarianceFeature(C3 ,C4 ,starTimeVARC3 ,starTimeVARC4 ,totalTrialTime,dataBase)

if(size(dataBase,2) ~= 1)
    % for extracting data from the test
    ResultC4 = std((dataBase(:,starTimeVARC4:totalTrialTime,C4)'));
    ResultC3 = std((dataBase(:,starTimeVARC3:totalTrialTime,C3)'));
else
    ResultC4 = std((dataBase.data(:,starTimeVARC4:totalTrialTime,C4)'));
    ResultC3 = std((dataBase.data(:,starTimeVARC3:totalTrialTime,C3)'));
end

VARC3 = ResultC3.^2;
VARC4 = ResultC4.^2;
```

בעזרת הפונקציה std נחשב את השונות עבור טווחי הזמן שנבחרו (גם כאן – ראה פירוט בפרק התוצאות בגרף 4). את התוצאות נעלה בריבוע, וכך נקבל את וקטורי השוניות שחושבו בהבדלים גדולים יותר בין הערכים שחושבו, תוך שמירה על היחס.

מצורפים איתחולי הפרמטרים המציינים את הזמנים הרלוונטיים שנשלחו לפונקציות המתוארות לעיל. למעשה הם מייצגים את הדגימות המתאימות, כאשר הדגימה ה-512 היא תחילת השנייה

```
starTimeVARC3 = 512;
starTimeVARC4 = 555;
startTimeFreq18 = 660;
```

ה-6, והדגימה ה-660 היא מעט אחרי תחילת השנייה האחרונה.

```
totalTrialTime = size(dataBase.data,2); % total time of each trial
```

הכנת המידע, הקטנת המימדים שהתקבלו מהפיצ'רים והפונקציה PCA:

### dimensionality reduction on all the features:

```
[coeff,score,latent,tsquared,explained] = pca(featuresMatrix);

pc1 = score(:,1);
pc2 = score(:,2);
pc3 = score(:,3);

PCAVisualization2D(pc1,pc2,rightHandLabeled,leftHandLabeled,'2D PCA',fontSize,titleFontSize)

if(strcmp(pcaZscore,"off"))
    % 3D plotting of the PCA
    PCAVisualization3D(pc1,pc2,pc3,rightHandLabeled,leftHandLabeled,'3D PCA',fontSize,titleFontSize)
else
    % Zscore on PCA - for demonstrasion
    % the first 2 dims have exectly the same information
    [coeff,score,latent,tsquared,explained] = pca(featuresMatrixNormalized);

    pc1 = score(:,1);
    pc2 = score(:,2);
    pc3 = score(:,3);
    % 3D plotting of the PCA
    PCAVisualization3D(pc1,pc2,pc3,rightHandLabeled,leftHandLabeled,'3D PCA Using zscore',fontSize,titleFontSize)
end
```

בחינת המודל:

### classify

K-Fold cross validation testing the classifier

```
for i = 1:nOfTestsForModel
    trialsTestedSigned = zeros(numberOfTrials, 1);
    test_set_size = floor(numberOfTrials / k);
    [meanOfAccuracy,stdOfAccuracy] = ...
        kFoldCrossValUP2DATE(featuresMatrixNormalized, numberOfTrials, test_set_size,...
            indicationVec);
    accuraciesOfModel(i) = meanOfAccuracy;
    stdsOfModel(i) = stdOfAccuracy;
end
disp("The STD of the classifier: "+ mean(stdsOfModel))
disp("The MEAN of the classifier: "+ mean(accuraciesOfModel))
```

The STD of the classifier: 0.082784  
The MEAN of the classifier: 0.91639

הפונקציה k-fold cross validation



```

function [meanOfAccuracy,stdOfAccuracy] = ...
    kFoldCrossValUP2DATE(featuresMatrix, numberOfTrials, test_set_size,...
        indicationVec)
% doc
% preform k-Fold Cross Validation on a model
% make sure you use k >= 10
accuraciesOfModel = zeros(1,floor(numberOfTrials/test_set_size));
randVec = randperm(numberOfTrials);
j = 1;
for i = 1:test_set_size:numberOfTrials
    if( i+test_set_size <= numberOfTrials)
        testIndeces = randVec(i:i+test_set_size-1);
        trainIndeces = setdiff(randVec, randVec(i:i+test_set_size-1), ...
            'stable');
        classifyOutput = classify(featuresMatrix(testIndeces,:), ...
            featuresMatrix(trainIndeces,:), indicationVec(trainIndeces));
        accuracy = calculateAccuracy(indicationVec, testIndeces, ...
            classifyOutput);
        accuraciesOfModel(j) = accuracy;
        j = j+1;
    end
end

stdOfAccuracy = std(accuraciesOfModel);
meanOfAccuracy = mean(accuraciesOfModel);

```

בהתאם לשם שלה – פונקציה זו מבצעת עבור המודל את הסיווג k פעמים; בתחילת הקוד היא מסדרת את מספרי החזרות 1-128 באופן אקראי בוקטור, ובכל פעם לוקחת testIndeces – אינדקסים המייצגים חזרות, באופן שזו תהיה זרה מכל הקודמות לה, בגודל  $128/k$  - זוהי קבוצת המבחן. שאר החזרות יוגדרו במידע לאימון – מיוצגות על ידי trainIndeces - זוהי קבוצת האימון. מטבלת המאפיינים featuresMatrix יישלחו המאפיינים המתאימים לכל חזרה בחלוקה של קבוצות אלו, יחד עם וקטור האימות – indicationVec, יישלחו לפונקציה classify, לטובת "אימון המסווג" – המסווג יתאים בין המאפיינים לסיווג הנתון לו בקבוצת האימון, ובשקלול המתאים למודל LDA יסווג את קבוצת המבחן – זהו פלט הפונקציה. את פלט זה יקבל וקטור התשובות classifyOutput, ובפונקציה calculateAccuracy יחושב הדיוק שלו על ידי השוואה עם וקטור האימות. לאחר חזרה על התהליך k פעמים, עבור k קבוצות מבחן, יחושבו ממוצע וסטיית התקן שנצברו בוקטורים המתאימים. זהו למעשה מימוש שיטת k-fold cross validation.

לאחר האימון - שליחת הפונקציה למציאת המאפיינים בקובץ המבחן:

#### predict using the model

```
load("motor_imagery_test_data.mat")
testData = data(:,1:2);
featuresMatrixOFTTEST = featureExtractor("compact",size(testData,1) , ...
    numOfFeatures,starTimeVARC3,starTimeVARC4,starTimeFreq18,samplingRate, ...
    totalTrialTime,starTimeFreq10,endTimefreq10C4, ...
    starTimeHighCloud,endTimeHighCloud, ...
    starTimeSpectralEntropy, ...
    starTimeApproxEntropyC3,starTimeApproxEntropyC4, ...
    endTimeApproxEntropyC3,endTimeApproxEntropyC4, ...
    starTimeImagination,starTimePSfeature, ...
    nOverLapPwelch,sizeOfPwelchVec,...
    sizeOfWindowPwelch,C3,C4,testData);

featuresMatrixOFTTEST = zscore(featuresMatrixOFTTEST);
```

ביצוע תהליך דומה עם מודל נוסף - בדיוק של 90.8%, ושונויות של 0.6%

#### using other Model (BONUS)

```
for i = 1 : nOfTestsForModel

    classificationSVM = fitcsvm(...
        featureTable, ...
        indicationVec, ...
        'KernelFunction', 'linear', ...
        'PolynomialOrder', [], ...
        'KernelScale', 'auto', ...
        'BoxConstraint', 1, ...
        'Standardize', true, ...
        'ClassNames', [0; 1]);

    % Perform cross-validation
    partitionedModel = crossval(classificationSVM, 'Kfold', 16);

    % Compute validation predictions
    [validationPredictions, validationScores] = kfoldPredict(partitionedModel);

    % Compute validation accuracy
    validationAccuracy = 1 - kfoldLoss(partitionedModel, 'LossFun', 'ClassifError');
    % Save the accuracy of this model
    accuraciesOfOTHERModel(i) = validationAccuracy;

end

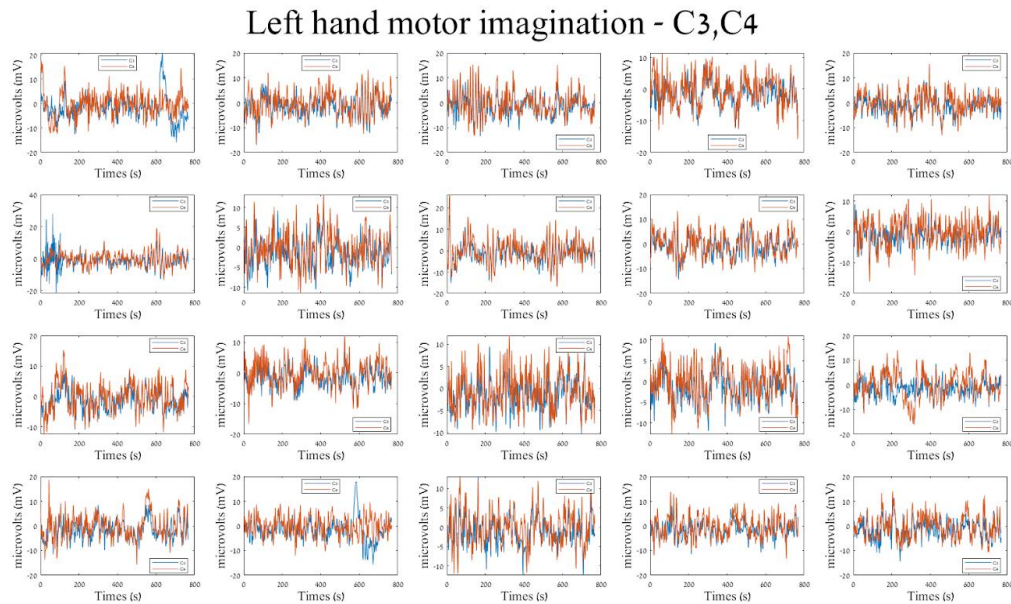
% what is the % of accuracy of the model
disp("The STD of the SVM model: " + std(accuraciesOfOTHERModel))
disp("The MEAN of the SVM model: " + mean(accuraciesOfOTHERModel))
resultOfSVMModel = predict(classificationSVM, featuresMatrixOfTEST);
```

The STD of the SVM model: 0.0062061

The MEAN of the SVM model: 0.90859

## תוצאות

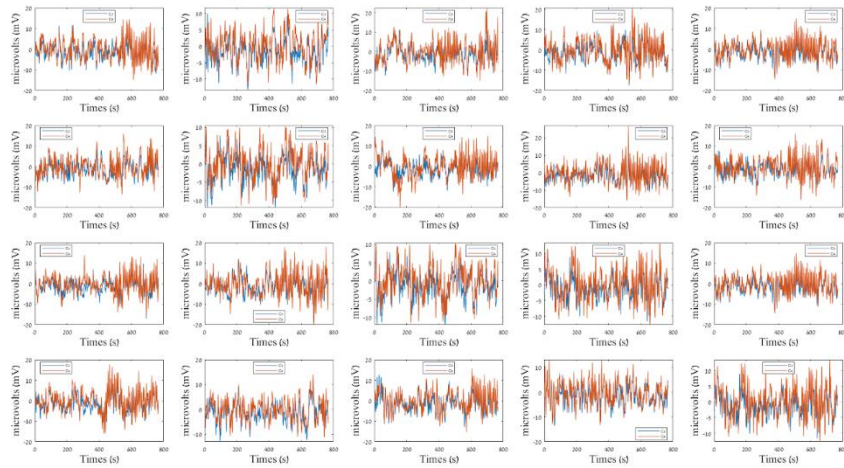
### גרף 1 – 20 גרפים בדיקות אקראיות של יד שמאל



בגרף זה מוצגים ערכי הדגימות שהתקבלו עבור 20 חזרות של יד שמאל, למשך כל זמן הניסוי. ניתן לראות שקיימות חזרות עם שונות גדולה בעוצמה שהתקבלה בדגימות, בעוד באחרים השונות אינה גדולה במיוחד.

### גרף 2 - 20 גרפים בדיקות אקראיות של יד ימין


### Right hand motor imagination - C3,C4



בגרף זה מוצגים ערכי הדגימות שהתקבלו עבור 20 חזרות של יד ימין, למשך כל זמן הניסוי.

### גרף 3 – Pwelch

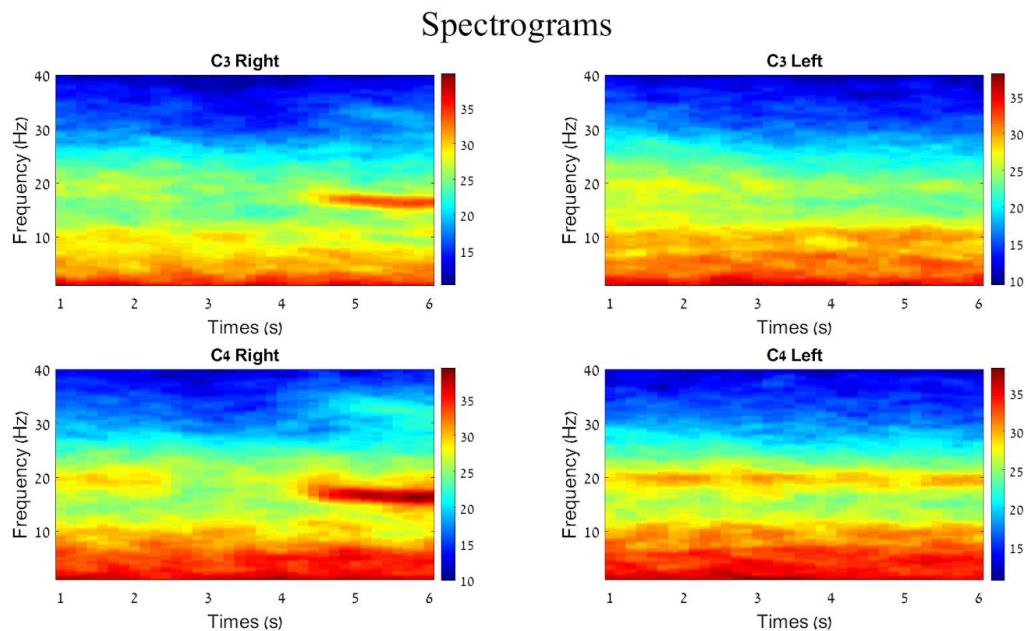
#### Average Power Spectra across trails



בגרף זה ניתן לראות שני תתי גרפים המחשבים את ה- power spectra - המרה וייצוג של עוצמת הסיגנל - ציר ה-Y (עוצמה בdB/Hz) למרחב התדר - ציר ה-X. כל תת גרף מייצג אלקטרודה -

C3 (עליונה), C4 (תחתונה). הגרף האדום מייצג חזרות של יד ימין והכחול של יד שמאל. ניתן לראות שבדמיון יד ימין עוצמת רצועת התדרים בתחום 16-18 Hz גבוהה משמעותית משאר התדרים בסביבה.

#### גרף 4 – ספקטוגרמה לכל רמה בכל אלקטרודה



בגרף זה ניתן לראות ארבעה תתי גרפים - Spectrograms - המרה וייצוג של הסיגנל למרחב התדר (ציר Y – תדרים 0-40) כתלות בזמן (ציר X - בשניות) הצבע בכל חלון מייצג את עוצמת התדר בנקודה המתאימה בזמן, כאשר כחול הוא העוצמה הנמוכה ביותר שנמדדה, ואדום כהה העוצמה הגבוהה ביותר.

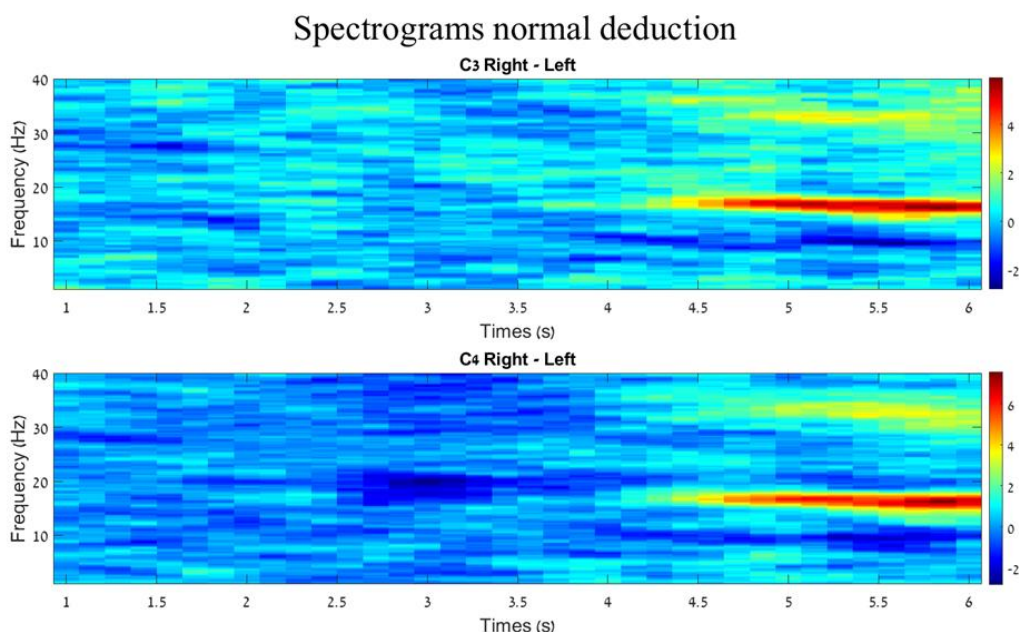
בעזרת חישוב של short-time fourier transformation, המחושב על פני כל החזרות. תתי הגרפים העליונים מייצגים את אלקטרודה C3, והתחתונים את C4, השמאליים את יד ימין והימניים את יד שמאל. כך לדוגמה, תת הגרף השמאלי התחתון מייצג את כל הניסויים שהוקלטו מאלקטרודה C4 ומתוייגים כ"ימין".

ניתן להבחין כי בתת גרף זה העוצמה בתדרים 15-19 היא הגבוהה ביותר בשניה וחצי האחרונות, וגם ביחס לכל שאר תתי הגרפים. תופעה דומה בעוצמה מעט יותר נמוכה תועדה באותו תנאי באלקטרודה C3. גם בתדרים 33 עד 35 ניתן לראות ממצא דומה ביד ימין בשתי האלקטרודות

בשניה האחרונה, אך בעוצמה נמוכה הרבה יותר, בתנאי יד שמאל, אמנם ניתן להבחין בעוצמה גבוהה יותר בסביבת התדר ה-20, אך לא נראים שינויים בעוצמה גבוהה במיוחד לאורך 6 שניות הניסוי.

בנוסף, ניתן לראות כי על פני כלל התדרים, ישנה שונות גדולה בעוצמת כל התנאים בטווח זמן דומה.


### גרף 5 – הפרשי הספקטוגרמות בין יד ימין ליד שמאל עבור כל אלקטרודה



בגרף זה ניתן לראות את ההפרשים בין הרמות בכל אלקטרודה בכל תת גרף. בגרף זה ניתן להבחין טוב יותר בהבדלים משמעותיים בין הרמות עבור אותה האלקטרודה; ניתן לראות באופן ישיר שנמדד הפרש דומה בשתי האלקטרודות בין ימין לשמאל בעוצמות התדרים בטווחים 15-18, 33-36, בשניות 4.5 עד 6. זאת אומרת שבממוצע על כל הניסויים באיזורים אלו התדרים הללו בעוצמה גדולה יותר בדמיון מוטורי של יד ימין מאשר יד שמאל.

ניתן להבחין גם באלקטרודה C4 בצבע כחול כהה, המעיד על עוצמה גבוהה יותר בתנאי יד שמאל, בסביבת תדר 20 באמצע הניסוי (בסביבת השניה השלישית), כמו גם בהפרש דומה בתדרים 9-10 בשניה האחרונה לניסוי, בשתי האלקטרודות.


#### גרף 5 - היסטוגרמת מאפיין שונות C4



ניתן לראות בהיסטוגרמה זו שמאפיין השונות של C4 מייצר התפלגויות שונות מאד (מפריד בצורה די מדויקת בין חזרות של יד ימין לחזרות של יד שמאל).


#### גרף 6 - היסטוגרמת מאפיין שונות C3






היסטוגרמת מאפיין השונות של C3 שמוסיף הבחנה למאפיין המוצג הקודם, ע"פ מידע מאלקטרודה שונה, לטובת משימת הסיווג.

**גרף 7 - דירוג 3 המאפיינים**




בגרף זה ניתן לראות את דירוג 3 המאפיינים שנבחרו. ניתן לראות כי חשיבות הניבוי של מאפיין השונות בC4 קרובה למקסימלית.

גרף 8 - דירוג כלל המאפיינים שנמצאו (מודל 1)

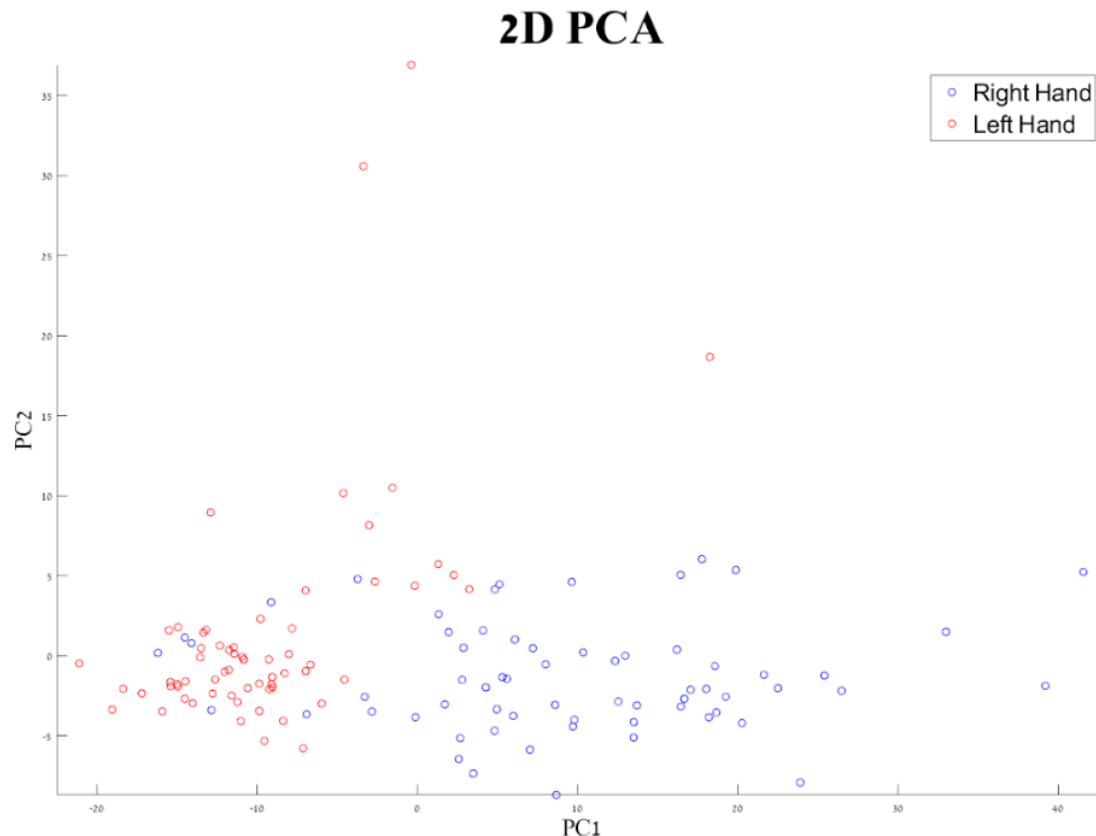


## גרף 9 - דירוג כלל המאפיינים שנמצאו (מודל 2)



ניתן לראות בשני הגרפים 8 ו-9, שכל מודל דירג את חשיבות המאפיינים בסדר שונה באופן משמעותי. ייתכן והבדל זה מסביר את הממצא שכאשר הוספנו מאפיינים אחרים ל3 המאפיינים שנבחרו, התקבל דיוק נמוך יותר מאשר כאשר רק שלושתם שוקללו בחישוב.

## גרף 10 – Scatter 2D -




בגרף זה מוצגים שני המימדים שמסבירים את רוב השונות שנובעת מהמאפיינים שבחרנו (מנורמלים לציוני תקן). באדום - ציוני החזרות שתוייגו כ"שמאל", בכחול - ציוני החזרות שתוייגו כ"ימין". ציר ה  $X$  - הרכיב האינפורמטיבי ביותר, ציר ה  $Y$  - הרכיב השני הכי האינפורמטיבי, שהתקבלו מהפונקציה PCA.

ההבחנה שמתקיימת בגרף בין רוב הנקודות האדומות לכחולות, היא אינדיקציה לסיווג שמבצעים המאפיינים לפני חישוב הפונקציה.

### גרף 11 – Scatter 3D

### 3D PCA Using zscore



בגרף זה מוצגת הצגה דומה בתוספת המימד השלישי הכי אינפורמטיבי. בדומה לגרף הקודם, לאחר נרמול לציוני התקן, ניתן לראות ב-2 זוויות את ההבחנה בין הצבעים.

ניתן לראות בשני הגרפים האחרונים שיש נקודות כחולות ש"נמצאות בתוך" קבוצת הנקודות האדומות. בעבודה זו אנו משתמשים במסווג לינארי - המשמעות הגיאומטרית של מסווג זה היא לחלק את 2 הקבוצות בחציית קו ישר בין כלל הנקודות, בצורה הטובה ביותר. בשימוש במסווג לינארי, המאפיינים שנמצאו אינם מספיקים לסיווג קרוב ל-100%, כיוון שאין הבחנה מלאה בין הקבוצה האדומה לקבוצה הכחולה.

## דיון

כפי שציפינו לראות, באופן כללי אכן נמדדה פעילות מוגברת בתדרים הנמוכים. בתדרי האלפא הנמוכים (8-10) ראינו פעילות מוגברת בכלל התנאים, בעוד שבתדרי הבטא הנמוכים (15-20) ראינו פעילות מוגברת באופן שונה בין 2 הרמות; ביד ימין ראינו פעילות שיא בשניה וחצי האחרונות (מה שאפשר לחלץ מאפיין בפונקציה  $\text{freq18}$ ). בעוד שביד שמאל ראינו פעילות גבוהה למשך כלל הניסוי, ובעוצמה מועטה בלבד באלקטרודה C3 (ראה גרף 4); בעזרת הבדלים אלה, המאפיינים של השונות הבחינו בצורה טובה בין 2 הרמות. את ההבדל ב-C3 בין הידיים ניתן להסביר בגלל הקרבה של האלקטרודה לצד שמאל, שאחראי לתנועה בצד ימין, ולהיפך. הסבר אפשרי לעוצמה החזקה של יד ימין בשתי האלקטרודות הוא שרוב החזרות התקבלו מנבדק ימני, ושדמיון תנועה כזו מעביר עוצמה חזקה וחדה יותר.

ניתן לראות שההיסטוגרמות שהתקבלו על ידי מאפיינים אלה הבחינו בצורה די מדויקת בין החזרות, וכך גם עבור מידע האימון ( $M = 91.6\%$ ,  $SD = 0.08$ ). גם במידע המבחן התקבלה תוצאה דומה במבחן האימון, בקירוב של 91%.

מנתונים אלה נסיק שניתן להבחין בצורה טובה באיזה יד נבדק מדמיין תנועה בעזרת מאפיינים אלו - עוצמת תדרי הבטא הנמוכים כשניה וחצי לאחר שהתחיל לדמיין (התחיל לדמיין מעט אחרי השניה השלישית), ובעזרת השונות בטווח זמן דומה. למרות ניסיון רב לדייק את המאפיינים הקיימים, ולהוסיף מאפיינים נוספים, אנו בכל זאת מאמינים שניתן לדייק עוד יותר את הניבוי בעזרת מציאת מאפיינים נוספים. במהלך עבודת החקר גם מצאנו שמודלים נוספים יוכלו להוסיף לדיוק הניבוי.

בנוסף, נושא יכול לתרום רבות לממשקי מוח-מחשב, כאשר תרגום דמיון של תנועה יכול לסייע בשיפור יכולות קיימות לשיקום כמו הזזת יד תותבת, שיקום, קריאת המחשבה של מבצע הדמיון, ולבחינת מכשירים ויכולות חדשות.

## ביבליוגרפיה

1. Venkatachalam K., Devipriya A., Maniraj J., Sivaram M., Ambikapathy A., S Amiri Iraj, A novel method of motor imagery classification using eeg signal, Artificial Intelligence in Medicine, Volume 103, 2020.
2. Jörn Munzert, Britta Lorey, Karen Zentgraf, Cognitive motor processes: The role of motor imagery in the study of motor representations, Brain Research Reviews, Volume 60, Issue 2, 2009.
3. Sivakami, A., & Devi, S. S., Analysis of EEG for motor imagery based classification of hand activities. International Journal of Biomedical Engineering and Science, 2(3), 11-22, 2015.
4. Athena Akrami, Soroosh Solhjoo, Ali Motie-Nasrabadi and Mohammed Reza Hashemi-Golpayegani, "EEG-Based Mental Task Classification: Linear and Nonlinear Classification of Movement Imagery", Proceedings of the 27th Annual Conference of the IEEE Engineering in Medicine and Biology Society, 2005.